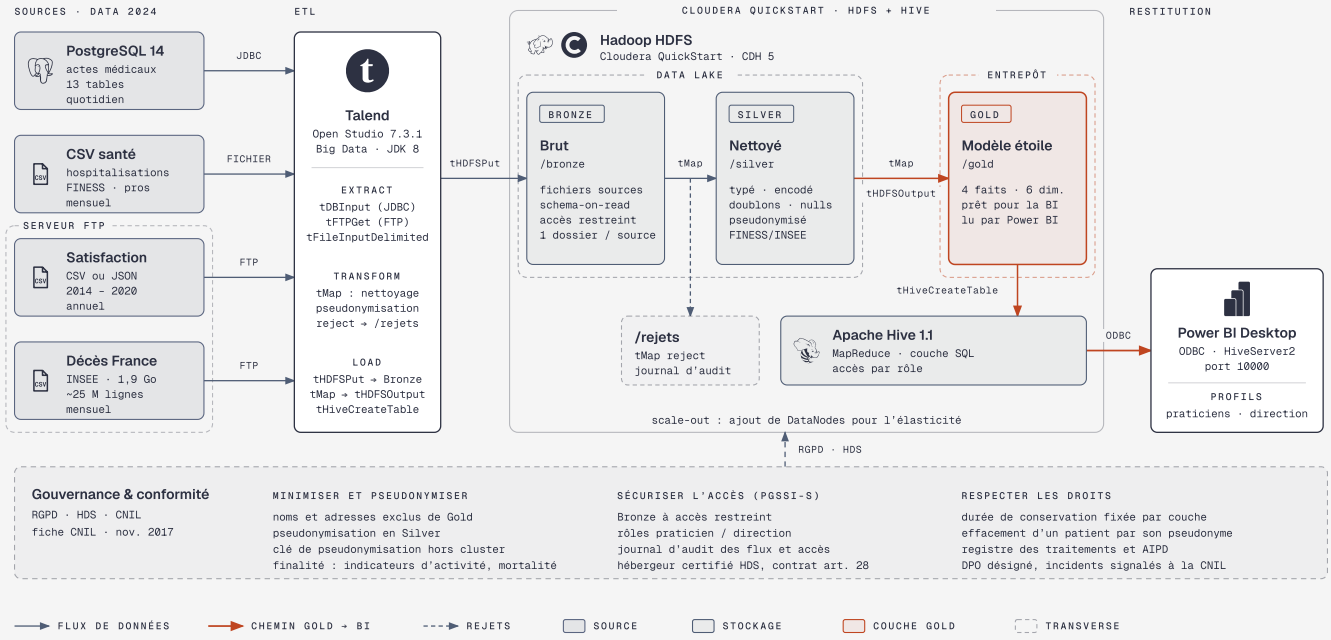
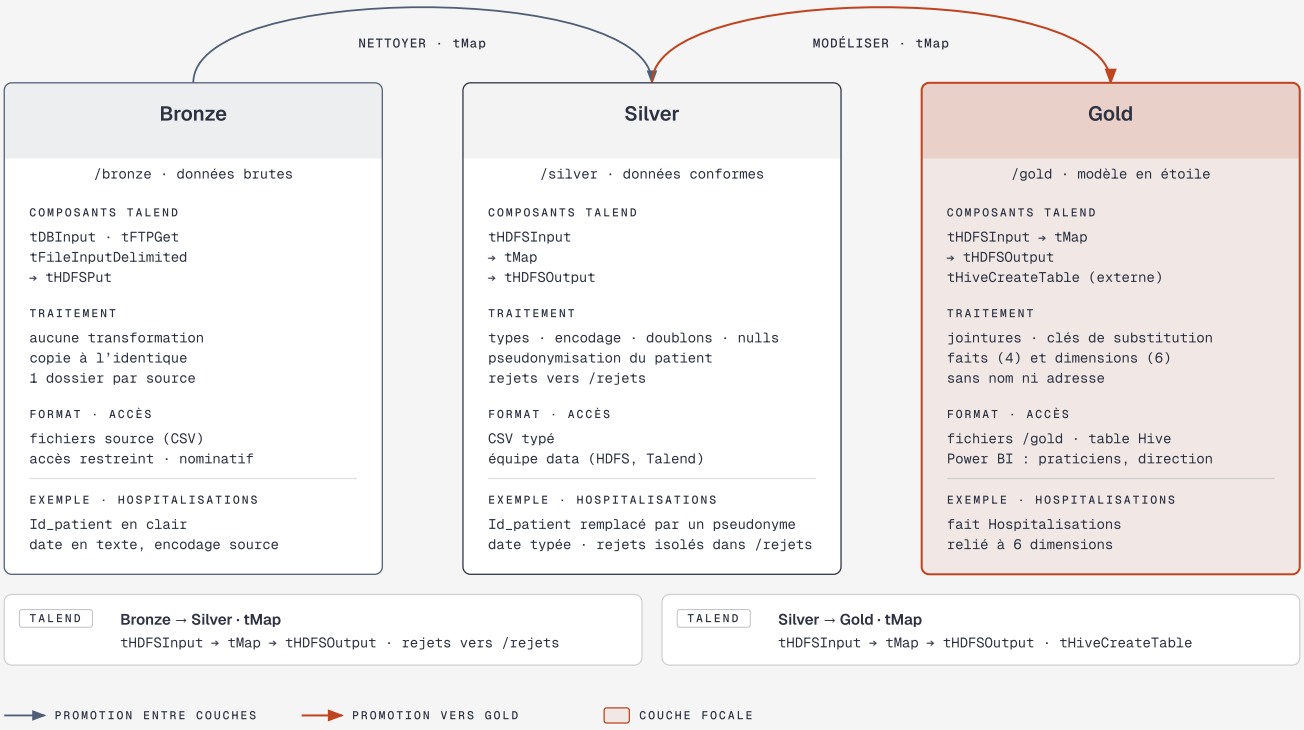
CLOUD HEALTHCARE UNIT · ARCHITECTURE CIBLE

# Sources → Talend → HDFS/Hive (Bronze · Silver · Gold) → Power BI




## Les trois couches en détail

Trois niveaux de qualité d'un même jeu de données, du fichier brut au modèle prêt pour la BI.




REJOUABILITÉ

### Reconstruire sans retourner à la source

Bronze conserve les fichiers tels qu'ils ont été reçus. Une règle de nettoyage erronée se corrige en rejouant Silver à partir de Bronze, sans retélécharger les 1,9 Go du fichier des décès.

TRAÇABILITÉ

### De l'indicateur au fichier d'origine

Chaque chiffre de Gold se remonte vers Silver, puis vers Bronze, puis vers la source. Le journal d'audit et le dossier /rejets documentent les lignes écartées.

RGPD

### Données nominatives isolées

Seul Bronze contient des identifiants en clair, d'où son accès restreint. La pseudonymisation a lieu au passage vers Silver ; Gold ne contient plus de nom ni d'adresse.

ETL

### Talend Open Studio for Big Data 7.3.1

tDBInput (JDBC) et tFTPGet (FTP) extraient les sources. tMap nettoie, pseudonymise et isole les rejets. tHDFSPut dépose les fichiers en Bronze ; tMap alimente Silver puis Gold (écrit par tHDFSOutput) ; tHiveCreateTable déclare la table externe Hive sur Gold. Édition open source, exécutée sur JDK 8.

STOCKAGE

### HDFS + Hive 1.1 sur Cloudera QuickStart

HDFS stocke les fichiers, Hive est la couche SQL posée sur Gold (table externe), pas un stockage de plus. Silver reste dans le data lake, sans table Hive. L'ajout de DataNodes assure l'élasticité. PostgreSQL reste une source, pas la cible.

BI

### Power BI Desktop

Connexion ODBC à HiveServer2 (pilote Cloudera, port 10000), lecture de Gold uniquement. Mesures DAX côté BI. Application locale, hors cluster.

GOLD · MODÈLE EN ÉTOILE

### 4 tables de faits, 6 dimensions

**Faits :** Consultations, Hospitalisations, Décès, Satisfaction.
**Dimensions :** Temps, Établissement, Patient anonymisé, Diagnostic, Professionnel, Région INSEE. Hive n'expose que Gold ; partitionnement et buckets sont adaptés aux axes d'analyse (période, région).

GOUVERNANCE DES DONNÉES

### RGPD, HDS, CNIL

Mesures issues de la fiche CNIL (novembre 2017) : minimisation et finalité (noms et adresses exclus de Gold), pseudonymisation du patient en Silver avec clé conservée hors cluster, Bronze à accès restreint, rôles par profil (praticiens, direction), journal d'audit, hébergeur certifié HDS lié par contrat (article 28), durée de conservation fixée par couche, effacement d'un patient par son pseudonyme, registre des traitements, analyse d'impact (AIPD) et DPO désigné.

COUVERTURE DES EXIGENCES

| | |
|---|---|
| Couches Bronze / Silver / Gold | Zone Cloudera : trois cartes reliées par tHDFSPut et tMap |
| Flux de bout en bout | Sources → Talend → HDFS → Hive → Power BI, chaque flèche porte son composant ou protocole |
| Erreurs et rejets | Dossier /rejets alimenté par la sortie reject de tMap, avec journal d'audit |
| Doublons et valeurs nulles | Étape TRANSFORM de Talend, carte Silver |
| Pseudonymisation RGPD | Carte Silver, bandeau Gouvernance (clé hors cluster) |
| HDS, rôles et droits, traçabilité | Bandeau Gouvernance, accès par rôle sur Hive, Bronze à accès restreint |
| Fréquence d'exécution | Libellé de fréquence sur chaque source |

| | |
|---|---|
| **Élasticité et scalabilité** | Note sous Hive : scale-out par ajout de DataNodes |