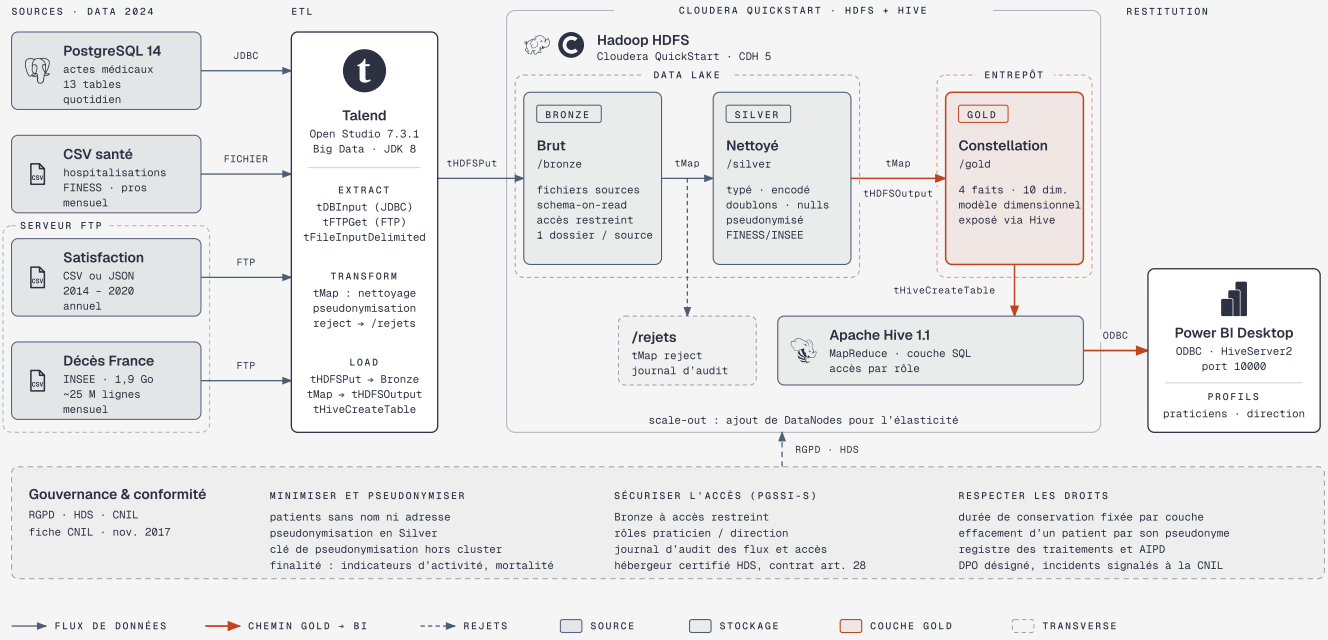
CLOUD HEALTHCARE UNIT · ARCHITECTURE CIBLE

Sources → Talend → HDFS/Hive (Bronze · Silver · Gold) → Power BI



ETL

Talend Open Studio for Big Data 7.3.1

tDBInput (JDBC) et tFTPGet (FTP) extraient les sources. tMap nettoie, pseudonymise et isole les rejets. tHDFSPut dépose les fichiers en Bronze ; tMap alimente Silver puis Gold (écrit par tHDFSOutput) ; tHiveCreateTable déclare la table externe Hive sur Gold. Édition open source, exécutée sur JDK 8.

STOCKAGE

HDFS + Hive 1.1 sur Cloudera QuickStart

HDFS stocke les fichiers, Hive est la couche SQL posée sur Gold (table externe), pas un stockage de plus. Silver reste dans le data lake, sans table Hive. L'ajout de DataNodes assure l'élasticité. PostgreSQL reste une source, pas la cible.

BI

Power BI Desktop

Connexion ODBC à HiveServer2 (pilote Cloudera, port 10000), lecture de Gold uniquement. Mesures DAX côté BI. Application locale, hors cluster.

GOLD · CONSTELLATION ET ÉTOILES

4 tables de faits, 10 dimensions

Faits : Consultations, Hospitalisations, Décès, Satisfaction.
Dimensions : Temps, Patient, Diagnostic, Professionnel et Établissement (avec un pont professionnel-établissement) partagées par les consultations et les hospitalisations ; Temps, Lieu et Défunt pour les décès ; Année et Établissement pour la satisfaction. Hive n'expose que Gold ; partitionnement et buckets sont adaptés aux axes d'analyse (période, localisation).

GOUVERNANCE DES DONNÉES

RGPD, HDS, CNIL

Mesures issues de la fiche CNIL (novembre 2017) : minimisation et finalité (nom et adresse des patients exclus de Gold ; nom et prénom des défunts conservés, point à trancher), pseudonymisation du patient en Silver avec clé conservée hors cluster, Bronze à accès restreint, rôles par profil (praticiens, direction), journal d'audit, hébergeur certifié HDS lié par contrat (article 28), durée de conservation fixée par couche, effacement d'un patient par son pseudonyme, registre des traitements, analyse d'impact (AIPD) et DPO désigné.

COUVERTURE DES EXIGENCES

Couches Bronze / Silver / Gold	Zone Cloudera : trois cartes reliées par tHDFSPut et tMap
Flux de bout en bout	Sources → Talend → HDFS → Hive → Power BI, chaque flèche porte son composant ou protocole
Erreurs et rejets	Dossier /rejets alimenté par la sortie reject de tMap, avec journal d'audit
Doublons et valeurs nulles	Étape TRANSFORM de Talend, carte Silver
Pseudonymisation RGPD	Carte Silver, bandeau Gouvernance (clé hors cluster)
HDS, rôles et droits, traçabilité	Bandeau Gouvernance, accès par rôle sur Hive, Bronze à accès restreint
Fréquence d'exécution	Libellé de fréquence sur chaque source
Élasticité et scalabilité	Note sous Hive : scale-out par ajout de DataNodes