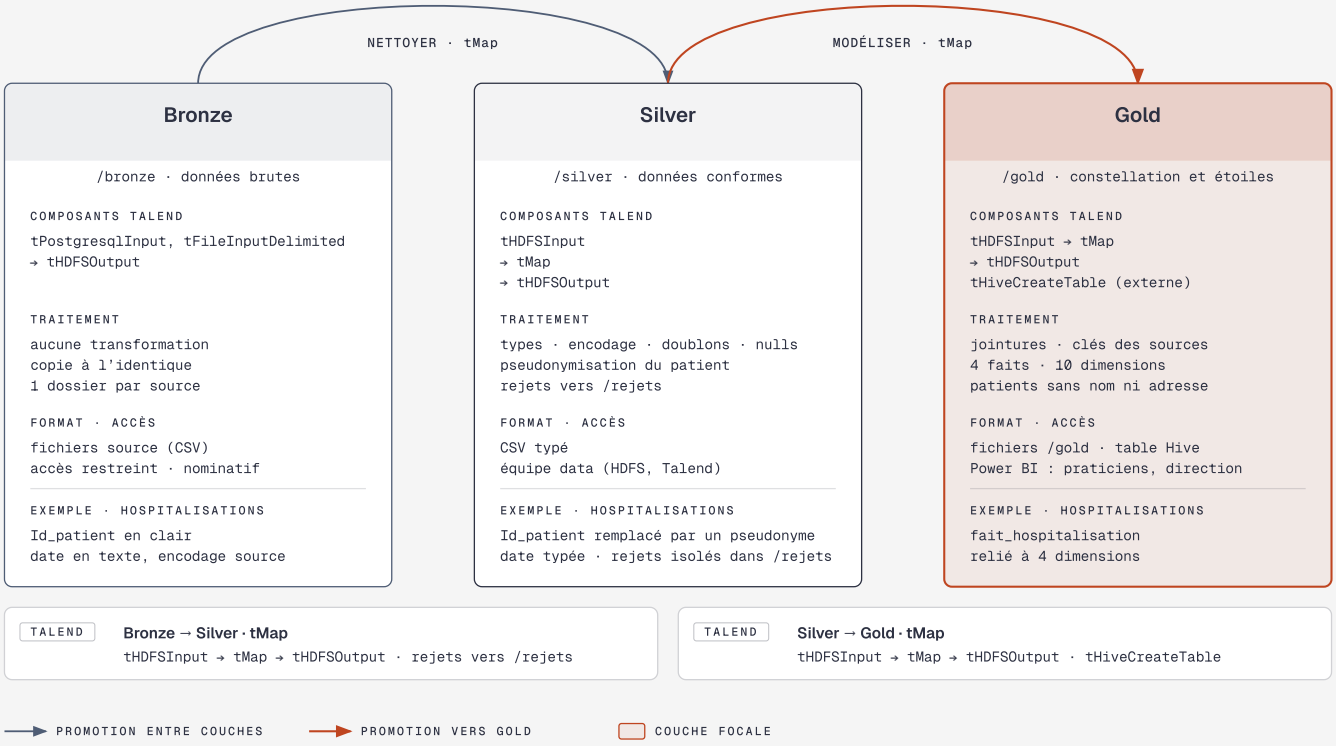
CLOUD HEALTHCARE UNIT · COUCHES DE DONNÉES

Architecture en médaillon : Bronze · Silver · Gold

Trois niveaux de qualité d'un même jeu de données, du fichier brut au modèle prêt pour la BI.



REJOUABILITÉ

Reconstruire sans retourner à la source

Bronze conserve les fichiers tels qu'ils ont été reçus. Une règle de nettoyage erronée se corrige en rejouant Silver à partir de Bronze, sans retélécharger les 1,9 Go du fichier des décès.

TRAÇABILITÉ

De l'indicateur au fichier d'origine

Chaque chiffre de Gold se remonte vers Silver, puis vers Bronze, puis vers la source. Le journal d'audit et le dossier /rejets documentent les lignes écartées.

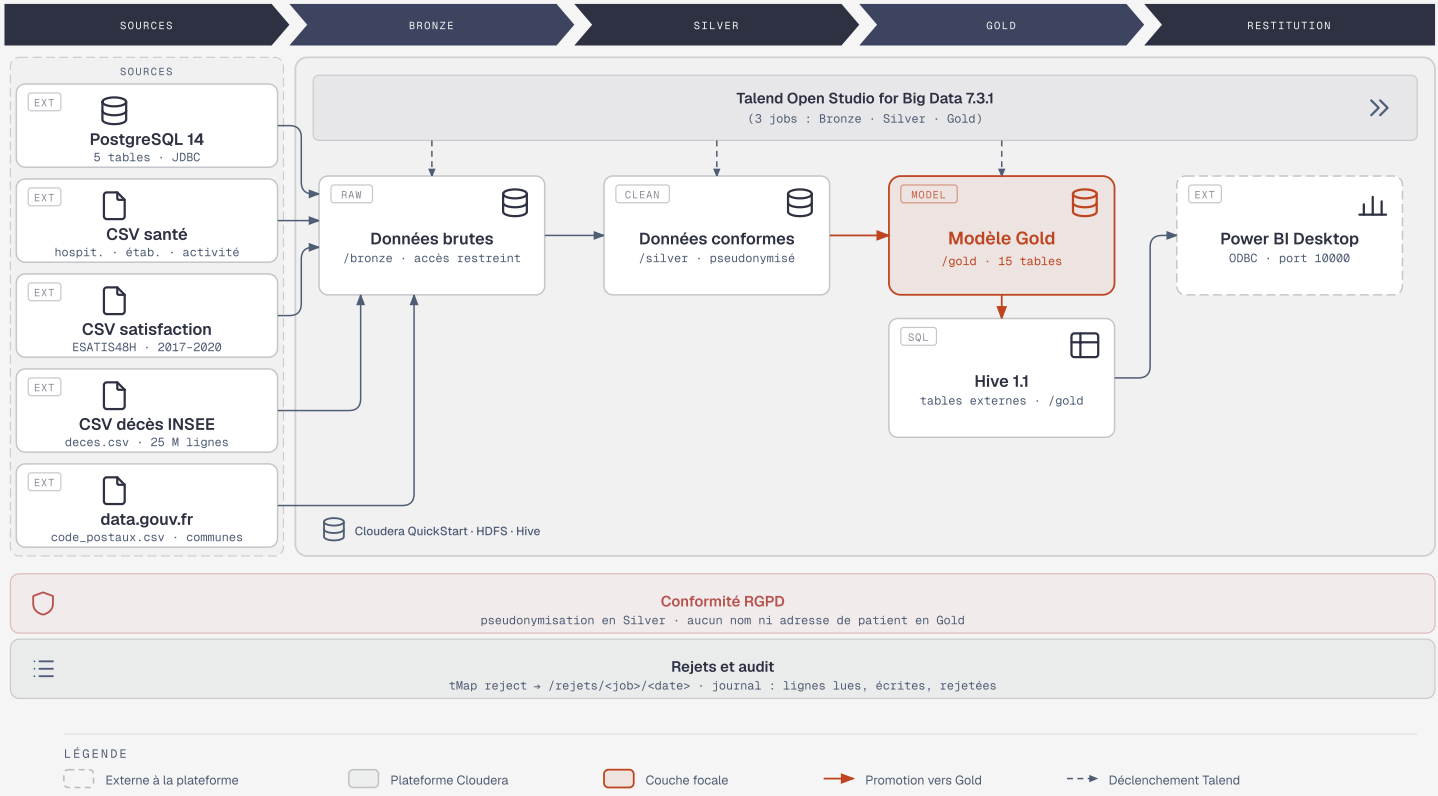
RGPD

Données nominatives isolées

Seul Bronze contient des identifiants en clair, d'où son accès restreint. La pseudonymisation a lieu au passage vers Silver ; Gold ne contient ni nom ni adresse de patient ; seule dim_defunt garde nom et prénom (point RGPD ouvert).

Pipeline de bout en bout

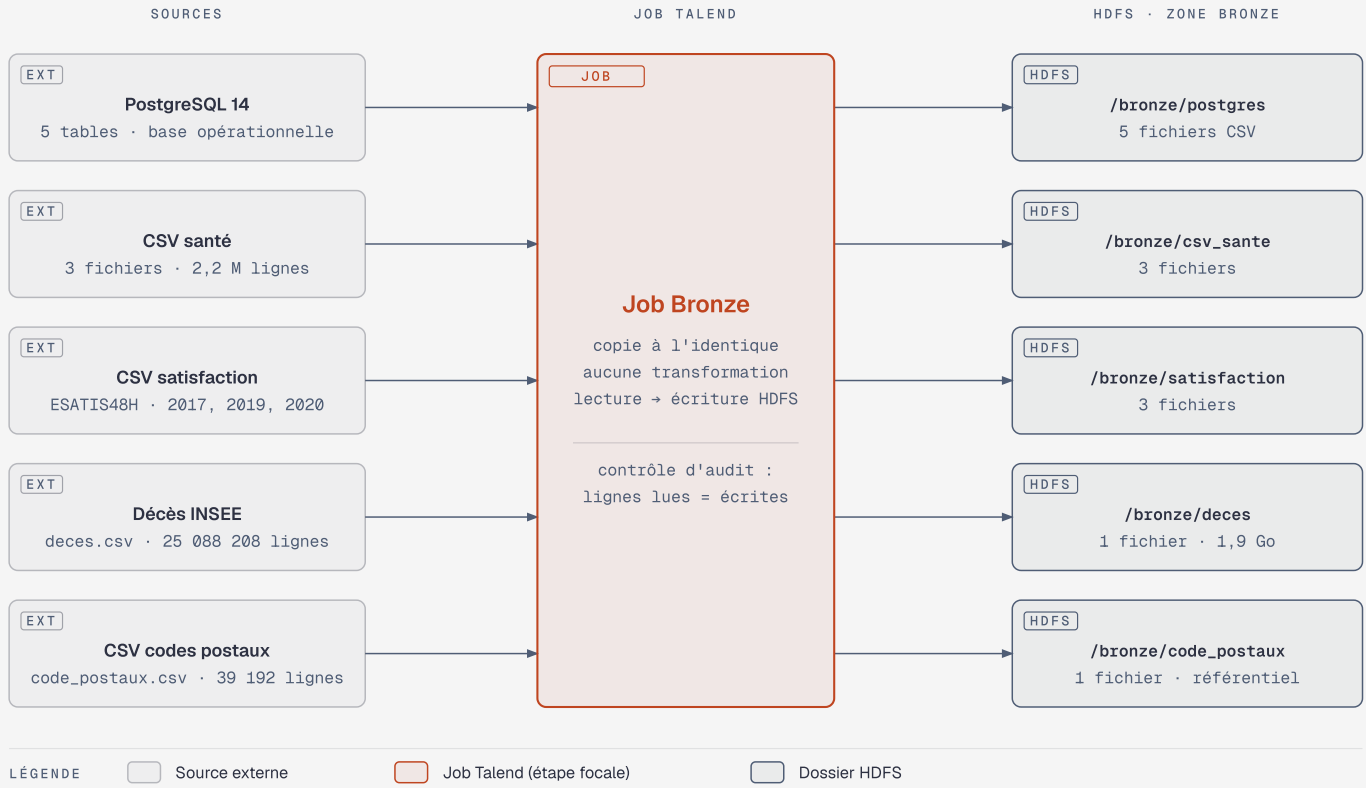
Des sources CSV et PostgreSQL à Power BI : les jobs Talend alimentent Bronze, Silver puis Gold, et Hive expose Gold en lecture seule. Le RGPD, les rejets et l'audit traversent toutes les couches.



Jobs Talend : vue canevas

Trois jobs Talend sont prévus, un par couche : Bronze, Silver et Gold, chacun exporté en un seul exécutable. Ils sont décrits ici à l'étape de conception, avant toute construction dans Talend Open Studio. Pour chaque couche, un schéma montre le flux des données, et un tableau reprend les critères du livrable : sources, règles de transformation, valeurs nulles, doublons, erreurs et rejets.

Bronze : copie des sources vers HDFS



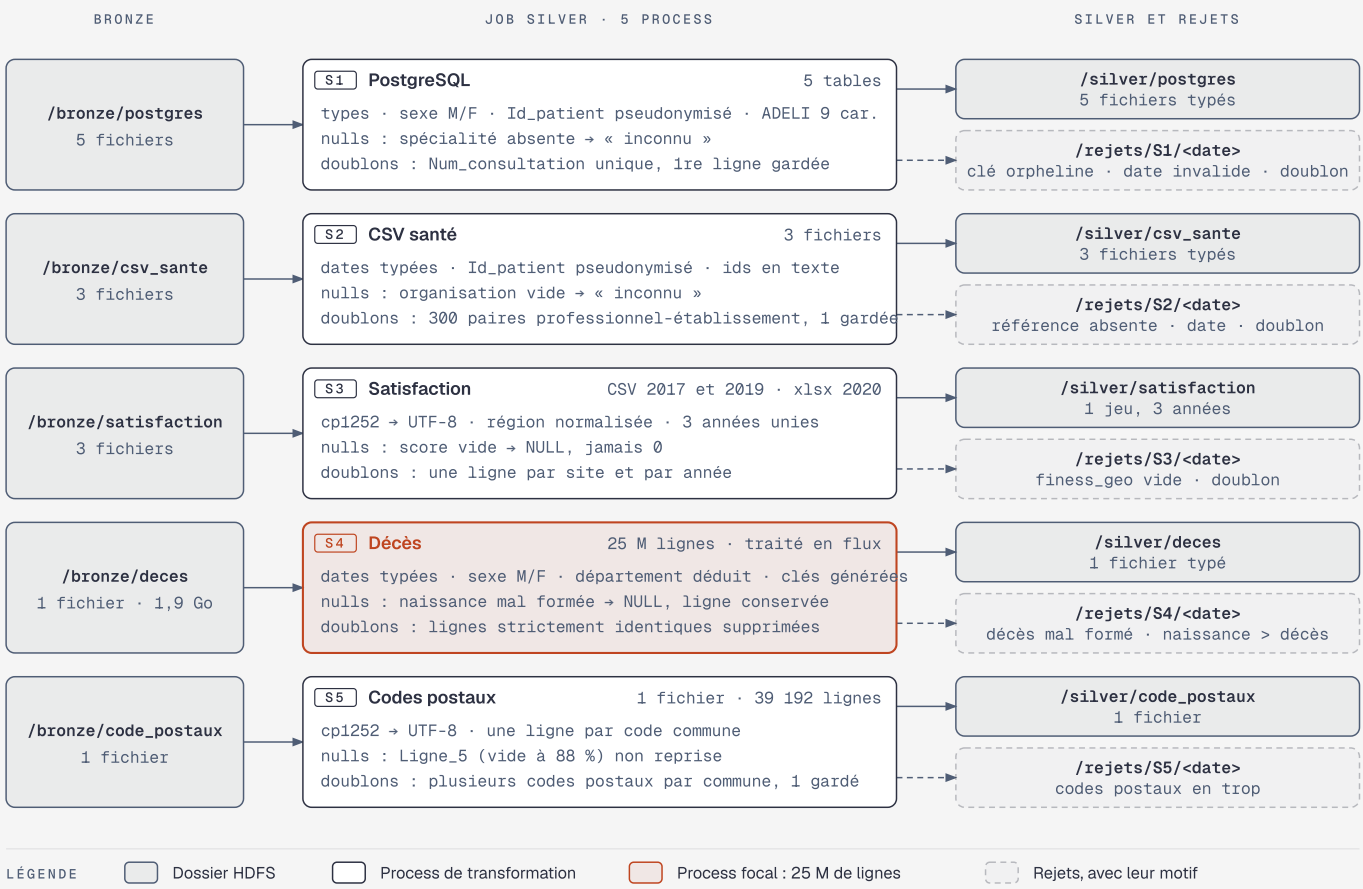
Pourquoi cette règle : Bronze garde les fichiers reçus tels quels. Silver et Gold peuvent donc être rejoués sans retourner à la source.

Les critères du livrable pour Bronze

SOURCE	CONTENU	RÈGLES DE TRANSFORMATION	VALEURS NULLES	DOUBLONS
PostgreSQL 14	5 tables : Consultation, Patient, Diagnostic, Professionnel_de_sante, Specialites	aucune	conservées telles quelles	conservés (aucun doublon dans Patient ni Consultation)
CSV santé	Hospitalisations, etablissement_sante, activite_professionnel_sante	aucune	conservées (finess_site vide à 99,95 %)	conservés (300 couples en double dans activité, 16 clés en double dans établissements)
CSV satisfaction	ESATIS48H 2017, 2019, 2020	aucune	conservées telles quelles	conservés tels quels
Décès INSEE	deces.csv, 25 088 208 lignes (1,9 Go)	aucune	conservées (dates de naissance mal formées : 89 863 ; vides : 550)	conservés (numero_acte_deces non unique)
CSV codes postaux	code_postaux.csv, 39 192 lignes (35 007 communes)	aucune	conservées (Ligne_5 vide à 88 %)	conservés (plusieurs codes postaux par commune : traités en Silver)

Erreurs et rejets : Bronze ne rejette aucune ligne. Un fichier absent, illisible ou tronqué fait échouer le job, et la dernière version déposée dans /bronze reste intacte. Le journal d'audit compare les lignes lues et écrites.

Silver : nettoyage, pseudonymisation, dédoublonnage



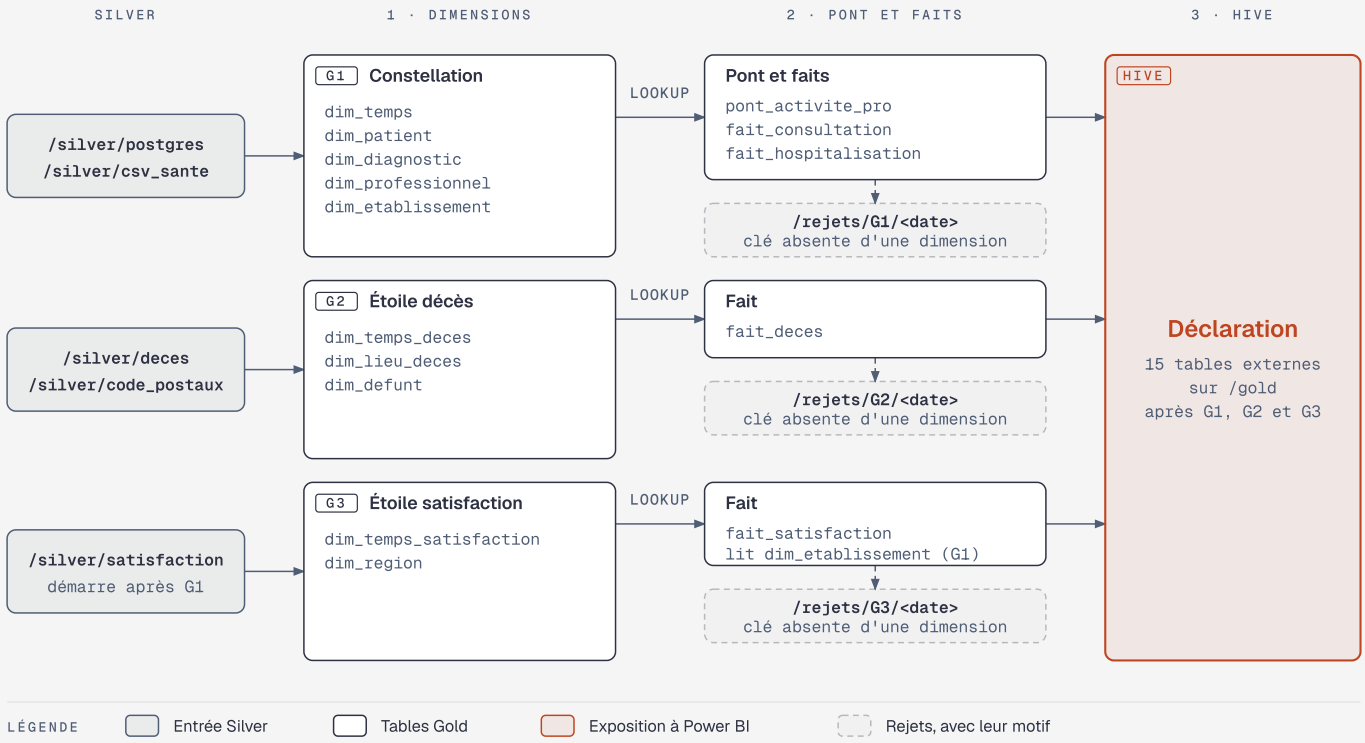
Pourquoi cette règle : Silver est la couche où l'on corrige : types, pseudonymisation, doublons. Rien ne disparaît sans trace : une ligne écartée est écrite dans /rejets/<job>/<date> avec ses colonnes d'origine, le motif et l'horodatage.

Les critères du livrable pour Silver

PROCESS	RÈGLES DE TRANSFORMATION	VALEURS NULLES	DOUBLONS	REJETS
S1 · PostgreSQL	Date typée ; sexe male/female converti en M/F ; Id_patient pseudonymisé (même fonction dans tous les jobs, pour garder les jointures) ; identifiants de professionnel en texte, ADELI complétés à 9 chiffres (zéro de tête perdu sur 36 172 lignes) ; libellé de spécialité ajouté par jointure.	Aucune clé nulle observée ; une clé nulle serait rejetée. Spécialité absente : « inconnu ».	Num_consultation est unique : première ligne gardée, doublons rejetés.	Id_patient, Code_diag ou Id_prof_sante absent de sa table ; date invalide.
S2 · CSV santé	Date_Entree typée ; Id_patient pseudonymisé ; Code_diagnostic renommé code_diag ; identifiants en texte (codes corses 2A et 2B) ; 24 colonnes d'établissements conservées.	identifiant_organisation vide sur 19,7 % des lignes d'activité (358 814) : ligne écartée du pont, professionnel rattaché à « inconnu ». mode_exercice vide (30) : « inconnu ».	300 paires professionnel-établissement en double : une seule gardée. Num_Hospitalisation et identifiant_organisation sont uniques.	Établissement absent de etablissement_sante, patient ou diagnostic inexistant, date invalide.
S3 · Satisfaction	Décodage cp1252 vers UTF-8 ; 2020 lu depuis un fichier xlsx ; année tirée du nom de fichier ; régions normalisées par table de correspondance ; trois années empilées.	Score vide (25 à 46 % selon l'année) : NULL conservé, jamais 0. Région vide : « inconnu ».	Une ligne par site (finess_geo) et par année : une seule gardée.	finess_geo vide. En-tête différent du modèle toléré (2017 sans taux_reco_brut ni nb_reco_brut).
S4 · Décès	Dates ISO typées ; sexe 1/2 converti en M/F ; espaces retirés de code_lieu_deces ; département déduit du code commune (97x, 2A et 2B, 99 = étranger) ; clés deces_key et defunt_key générées ; traitement en flux, jamais en mémoire.	date_naissance vide (550) ou mal formée (89 863) : NULL, ligne conservée. nom (96) et prénom (5 268) vides : « inconnu ». numero_acte_deces vide (31 606) : NULL. code_lieu_deces vide : « inconnu ».	numero_acte_deces n'est pas une clé. Ligne strictement identique supprimée. Homonymes conservés (223 249 lignes de plus), indiscernables de vrais doublons.	date_deces mal formée (646 lignes) ; date_naissance postérieure à date_deces (70 lignes).
S5 · Codes postaux	Décodage cp1252 vers UTF-8 ; # retiré du nom de la première colonne ; une ligne par code commune ; Ligne_5 non reprise.	Ligne_5 vide à 88 % : non reprise.	35 007 communes pour 39 192 lignes : le plus petit code postal est gardé pour chaque commune.	Codes postaux en trop (autres que le plus petit), écrits dans /rejets/S5.

Erreurs et rejets : chaque process écrit ses rejets dans /rejets/S1 à /rejets/S5. Le journal d'audit compare les lignes lues, écrites et rejetées : un écart signale une perte.

Gold : construction du modèle et déclaration Hive



Pourquoi cet ordre : un fait cherche ses clés dans les dimensions (lookups), elles doivent donc exister avant lui. G3 démarre après G1 car elle partage dim_etablissement ; G1 et G2 sont indépendants. Hive déclare les 15 tables à la fin, quand /gold est complet.

Les critères du livrable pour Gold

GROUPE	TABLES PRODUITES	RÈGLES DE TRANSFORMATION	VALEURS NULLES	DOUBLONS	REJETS
G1 · Constellation	dim_temps, dim_patient, dim_diagnostic, dim_professionnel, dim_etablissement, pont_activite_pro, fait_consultation, fait_hospitalisation	dim_temps : calendrier généré jour par jour, de la première à la dernière date des faits. dim_patient : tranche d'âge calculée, sans nom ni adresse. dim_etablissement : ligne « inconnu » ajoutée. pont_activite_pro : une ligne par couple professionnel-établissement. Les faits ne stockent aucune mesure : comptages et taux sont calculés dans Power BI.	Professionnel absent du fichier d'activité (56 583 professionnels de consultations, 28 %) ou sans établissement : rattaché à « inconnu » dans le pont.	Une ligne par clé dans chaque dimension (clés uniques depuis Silver). Num_consultation et Num_Hospitalisation sont uniques.	Fait dont une clé est absente de sa dimension (Hive 1.1 n'applique pas les contraintes) : /rejets/G1.
G2 · Étoile décès	dim_temps_deces, dim_lieu_deces, dim_defunt, fait_deces	dim_temps_deces : même calendrier, sans jour de la semaine. dim_lieu_deces : une ligne par code commune, lue depuis Silver (process S5). dim_defunt : une ligne par défunt, clé de substitution defunt_key. fait_deces : clé de substitution deces_key.	Code lieu absent ou vide : « inconnu » dans dim_lieu_deces. Les dates de naissance NULL venues de Silver sont conservées.	Aucun dédoublonnage ici, il est fait en Silver. numero_acte_deces n'est pas une clé ; les homonymes sont conservés.	Fait dont une clé est absente d'une dimension : /rejets/G2.
G3 · Étoile satisfaction	dim_temps_satisfaction, dim_region, fait_satisfaction	dim_temps_satisfaction : une ligne par année. fait_satisfaction : une ligne par établissement (identifiant_organisation = « F » + finess_geo) et par année ; mesures : score global et nombre de réponses.	Score vide : NULL conservé, jamais 0. Site sans correspondance dans dim_etablissement (0,3 % à 2,8 % des lignes selon l'année) : « inconnu ».	Clé du fait : identifiant_organisation et année, une seule ligne.	Fait dont une clé est absente d'une dimension : /rejets/G3.

GROUPE	TABLES PRODUITES	RÈGLES DE TRANSFORMATION	VALEURS NULLES	DOUBLONS	REJETS
		dim_etablissement est partagée avec G1.			

Erreurs et rejets : un fait dont une clé étrangère est absente de sa dimension est écrit dans /rejets/G1 à /rejets/G3 avec le motif ; le journal d'audit compare les lignes lues, écrites et rejetées.

Spécifications fonctionnelles des jobs ETL

Trois jobs Talend sont prévus, un par couche : Bronze (5 process), Silver (S1 à S5) et Gold (G1 à G3, puis la déclaration Hive). Chacun est exporté en un exécutable, lancé dans cet ordre. Les transformations, valeurs nulles, doublons et rejets de chaque couche sont dans les tableaux « Les critères du livrable » ci-dessus ; cette section donne les sources, la fréquence d'exécution, l'ordre de lancement et la gestion des erreurs.

1. Jobs, sources et fréquence d'exécution

PROCESS	SOURCE → CIBLE	COMPOSANTS TALEND	FRÉQUENCE OU ORDRE
Bronze postgres	PostgreSQL 14 : Consultation, Patient, Diagnostic, Professionnel_de_sante, Specialites → `/bronze/postgres`	tPostgresqlInput → tHDFSOutput	quotidien
Bronze csv_sante	Hospitalisations, etablissement_sante, activite_professionnel_sante → `/bronze/csv_sante`	tFileInputDelimited → tHDFSOutput	mensuel
Bronze satisfaction	ESATIS48H : CSV 2017 et 2019, xlsx 2020 → `/bronze/satisfaction`	tFileInputDelimited (CSV) ou composant Excel (2020) → tHDFSOutput	annuel
Bronze deces	`deces.csv` (25 088 208 lignes, 1,9 Go) → `/bronze/deces`	tFileInputDelimited → tHDFSOutput	mensuel
Bronze code_postaux	`code_postaux.csv` (39 192 lignes) → `/bronze/code_postaux`	tFileInputDelimited → tHDFSOutput	annuel
S1 à S5	un process par source : `/bronze/…` → `/silver/…` ; rejets dans `/rejets/S1` à `/rejets/S5`	tHDFSInput (+ lookups) → tMap → tUniqRow → tHDFSOutput ; tUnite pour S3	après Bronze
G1	Silver PostgreSQL et CSV santé → constellation (consultations, hospitalisations)	tHDFSInput → tMap → tHDFSOutput ; lookups tHDFSInput pour les faits	après S1 et S2
G2	Silver décès et codes postaux → étoile des décès	idem	après S4 et S5
G3	Silver satisfaction → étoile de la satisfaction	idem	après S3 et G1
Hive	Gold → déclaration des 15 tables externes	tHiveConnection → tHiveCreateTable (×15) → tHiveClose	après G1, G2 et G3

Les fréquences suivent le rythme de mise à jour de chaque source : la base opérationnelle change tous les jours, les fichiers de santé et le fichier des décès sont republiés chaque mois, la satisfaction une fois par an. Silver et Gold se relancent quand Bronze change. Les huit autres tables PostgreSQL (mutuelles, médicaments, prescriptions, salles, laboratoires, AAAA, date) ne sont pas extraites : aucune vue demandée ne les utilise.

2. Gestion des erreurs et des rejets

- Chaque process de Silver et chaque fait de Gold a une sortie de rejet. Les lignes rejetées sont écrites dans `/rejets/<process>/<date>` (S1 à S5, G1 à G3) avec toutes les colonnes d'origine, le motif et l'horodatage. Bronze ne rejette aucune ligne.
- Un journal d'audit est alimenté à chaque exécution : job, début, fin, lignes lues, écrites et rejetées. Un écart entre lues et écrites plus rejetées signale une perte.
- Un exécutable ne se lance que si le précédent s'est terminé sans erreur. En cas d'échec, on relance l'exécutable de la couche : Bronze conserve les fichiers reçus, donc Silver et Gold se rejouent sans retourner à la source.
- Fichier absent, illisible ou tronqué : le job échoue sans écraser la dernière version déposée en Bronze.
- Avant l'écriture de Gold, un contrôle d'intégrité référentielle vérifie que chaque clé étrangère d'un fait existe dans sa dimension.

3. Points ouverts

- Fichier code_postaux.csv : les codes DOM (97x, 98x) et corses (2A, 2B) sont présents. Il ne contient que les arrondissements de Paris, Lyon et Marseille (75101, 69381, 13201), pas la commune entière (75056, 69123, 13055) : la couverture des codes de deces.csv n'est pas mesurée.

- professionnel_sante.csv et la table Professionnel_de_sante ont exactement 1 048 575 lignes, la limite d'Excel : le fichier est probablement tronqué. Environ 28 % des consultations n'ont pas de professionnel dans le fichier d'activité.
- Tranches d'âge de dim_patient : bornes à fixer.
- Sites de satisfaction sans correspondance dans dim_etablissement : 0,3 % (2020) à 2,8 % (2017) des lignes, rattachés à « inconnu ». La clé de fait_satisfaction est identifiant_organisation + annee (finess_geo est unique, alors que finess ne l'est pas).
- Nom et prénom conservés dans dim_defunt : point RGPD à trancher.