CLOUD HEALTHCARE UNIT · ARCHITECTURE CIBLE

Sources ⟶ Talend ⟶ HDFS/Hive (Bronze · Silver · Gold) ⟶ Power BI

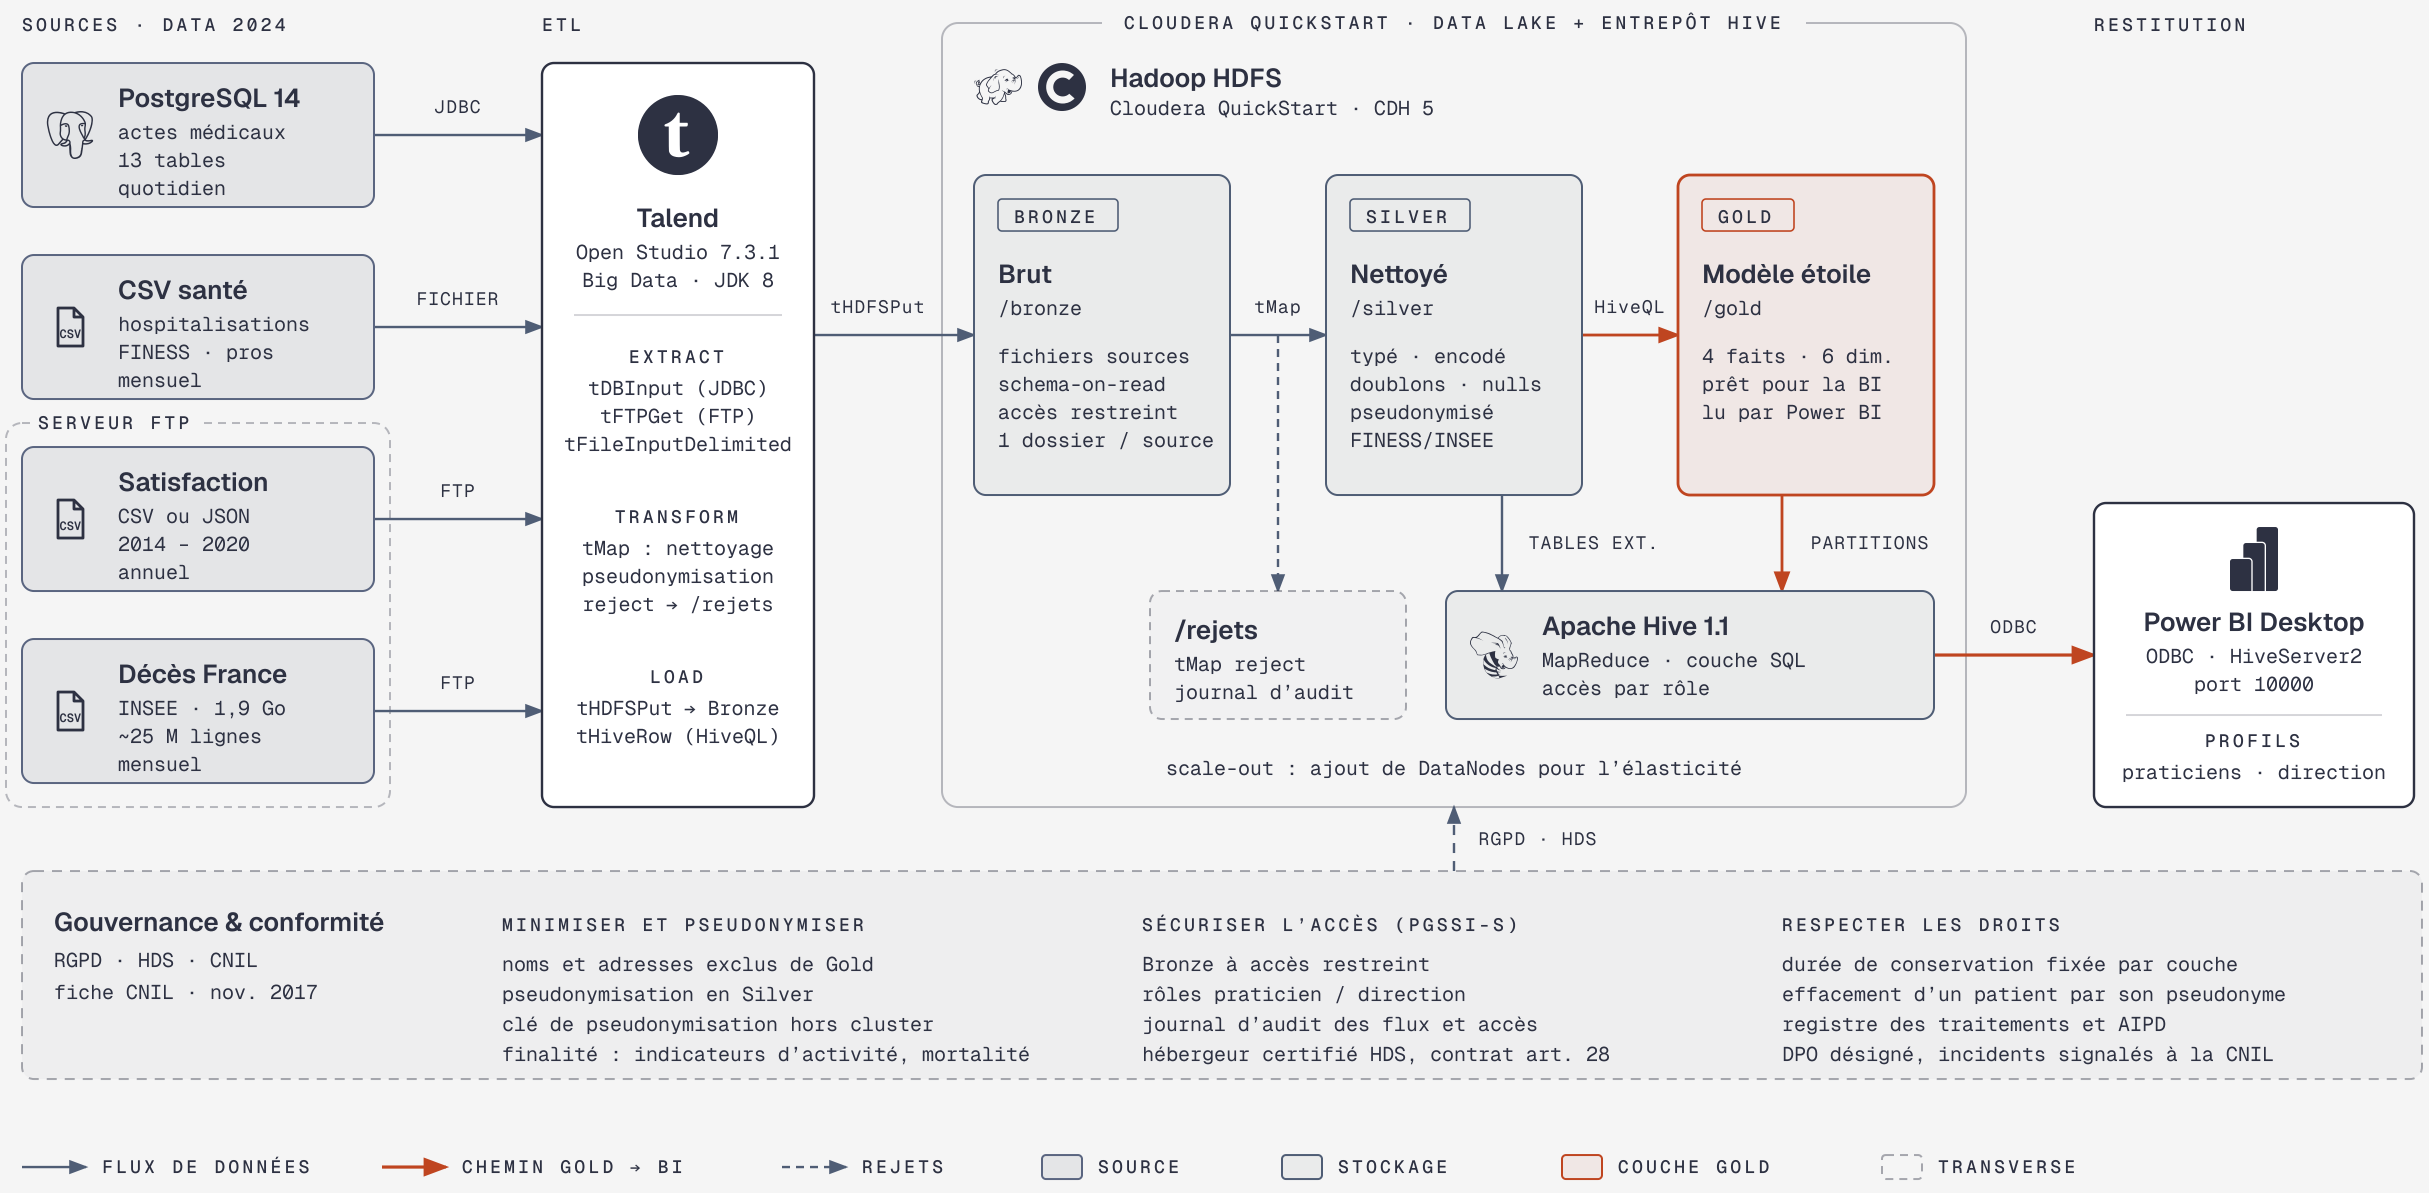

PostgreSQL 14
actes médicaux
13 tables
quotidien

CSV santé
hospitalisations
FINESS · pros
mensuel

SERVEUR FTP

Satisfaction
CSV ou JSON
2014 – 2020
annuel

Décès France
INSEE · 1,9 Go
~25 M lignes
mensuel

Talend
Open Studio 7.3.1
Big Data · JDK 8

EXTRACT
tDBInput (JDBC)
tFTPGet (FTP)
tFileInputDelimited

TRANSFORM
tMap : nettoyage
pseudonymisation
reject → /rejets

LOAD
tHDFSPut → Bronze
tHiveRow (HiveQL)

Hadoop HDFS
Cloudera QuickStart · CDH 5

BRONZE
Brut
/bronze
fichiers sources
schema-on-read
accès restreint
1 dossier / source

SILVER
Nettoyé
/silver
typé · encodé
doublons · nulls
pseudonymisé
FINESS/INSEE

GOLD
Modèle étoile
/gold
4 faits · 6 dim.
prêt pour la BI
lu par Power BI

/rejets
tMap reject
journal d'audit

Apache Hive 1.1
MapReduce · couche SQL
accès par rôle

scale-out : ajout de DataNodes pour l'élasticité

Power BI Desktop
ODBC · HiveServer2
port 10000

PROFILS
praticiens · direction

Gouvernance & conformité
RGPD · HDS · CNIL
fiche CNIL · nov. 2017

MINIMISER ET PSEUDONYMISER
noms et adresses exclus de Gold
pseudonymisation en Silver
clé de pseudonymisation hors cluster
finalité : indicateurs d'activité, mortalité

SÉCURISER L'ACCÈS (PGSSI-S)
Bronze à accès restreint
rôles praticien / direction
journal d'audit des flux et accès
hébergeur certifié HDS, contrat art. 28

RESPECTER LES DROITS
durée de conservation fixée par couche
effacement d'un patient par son pseudonyme
registre des traitements et AIPD
DPO désigné, incidents signalés à la CNIL

⟶ FLUX DE DONNÉES · ⟶ CHEMIN GOLD → BI · - - -> REJETS · ☐ SOURCE · ☐ STOCKAGE · 🟥 COUCHE GOLD · ⬚ TRANSVERSE

Les trois couches en détail

Trois niveaux de qualité d'un même jeu de données, du fichier brut au modèle prêt pour la BI.

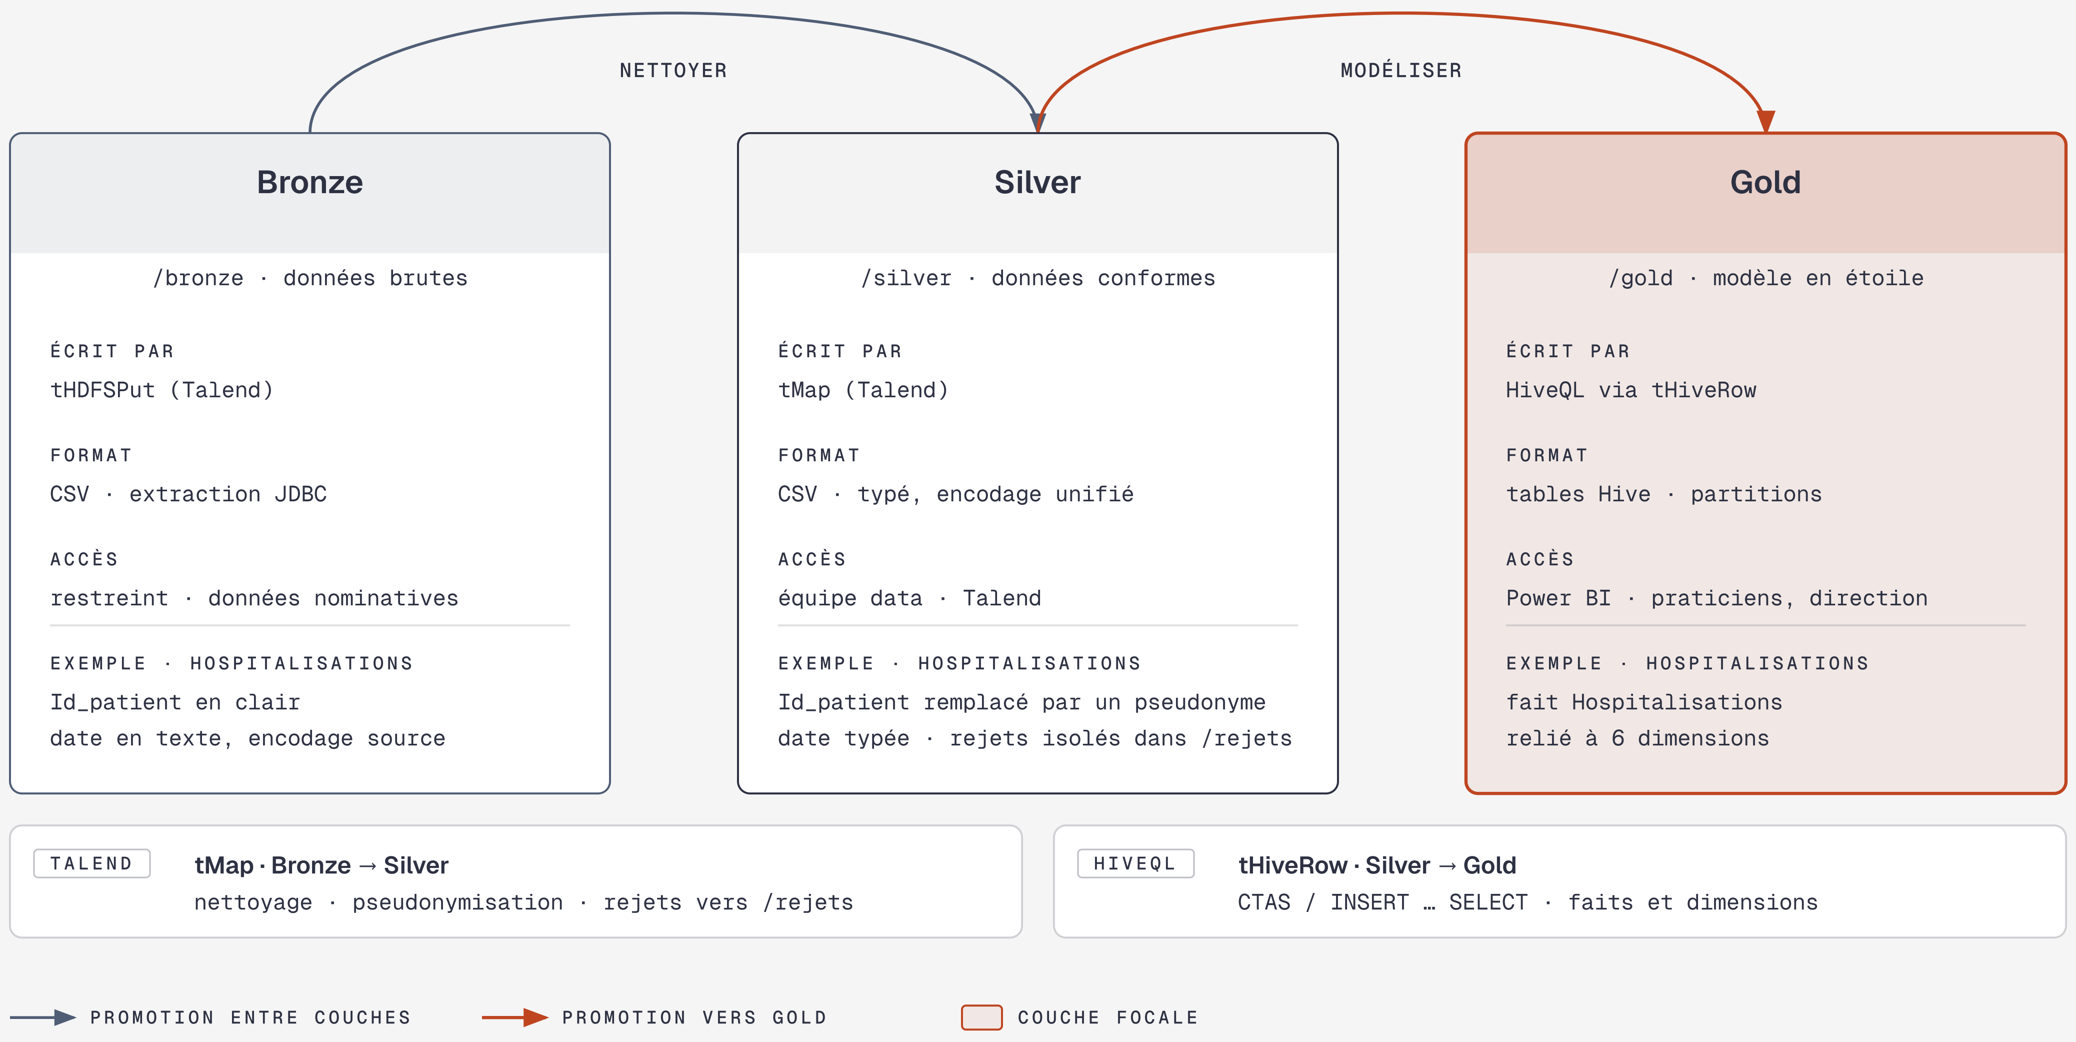

Bronze

/bronze · données brutes

ÉCRIT PAR
tHDFSPut (Talend)

FORMAT
CSV · extraction JDBC

ACCÈS
restreint · données nominatives

EXEMPLE · HOSPITALISATIONS
Id_patient en clair
date en texte, encodage source

Silver

/silver · données conformes

ÉCRIT PAR
tMap (Talend)

FORMAT
CSV · typé, encodage unifié

ACCÈS
équipe data · Talend

EXEMPLE · HOSPITALISATIONS
Id_patient remplacé par un pseudonyme
date typée · rejets isolés dans /rejets

Gold

/gold · modèle en étoile

ÉCRIT PAR
HiveQL via tHiveRow

FORMAT
tables Hive · partitions

ACCÈS
Power BI · praticiens, direction

EXEMPLE · HOSPITALISATIONS
fait Hospitalisations
relié à 6 dimensions

TALEND **tMap · Bronze → Silver**
nettoyage · pseudonymisation · rejets vers /rejets

HIVEQL **tHiveRow · Silver → Gold**
CTAS / INSERT … SELECT · faits et dimensions

⟶ PROMOTION ENTRE COUCHES · ⟶ PROMOTION VERS GOLD · 🟥 COUCHE FOCALE

REJOUABILITÉ

Reconstruire sans retourner à la source

Bronze conserve les fichiers tels qu'ils ont été reçus. Une règle de nettoyage erronée se corrige en rejouant Silver à partir de Bronze, sans retélécharger les 1,9 Go du fichier des décès.

TRAÇABILITÉ

De l'indicateur au fichier d'origine

Chaque chiffre de Gold se remonte vers Silver, puis vers Bronze, puis vers la source. Le journal d'audit et le dossier /rejets documentent les lignes écartées.

RGPD

Données nominatives isolées

Seul Bronze contient des identifiants en clair, d'où son accès restreint. La pseudonymisation a lieu au passage vers Silver ; Gold ne contient plus de nom ni d'adresse.

ETL

Talend Open Studio for Big Data 7.3.1

tDBInput (JDBC) et tFTPGet (FTP) extraient les sources. tMap nettoie, pseudonymise et isole les rejets. tHDFSPut dépose les fichiers en Bronze ; tHiveRow exécute le HiveQL (DDL, CTAS) qui construit Gold. Édition open source, exécutée sur JDK 8.

STOCKAGE

HDFS + Hive 1.1 sur Cloudera QuickStart

HDFS stocke les fichiers, Hive est la couche SQL posée dessus (tables externes sur Silver et Gold), pas un stockage de plus. L'ajout de DataNodes assure l'élasticité. PostgreSQL reste une source, pas la cible.

BI

Power BI Desktop

Connexion ODBC à HiveServer2 (pilote Cloudera, port 10000), lecture de Gold uniquement. Mesures DAX côté BI. Application locale, hors cluster.

GOLD · MODÈLE EN ÉTOILE

4 tables de faits, 6 dimensions

Faits : Consultations, Hospitalisations, Décès, Satisfaction.
Dimensions : Temps, Établissement, Patient anonymisé, Diagnostic, Professionnel, Région INSEE. Hive expose Silver et Gold ; partitionnement et buckets sont adaptés aux axes d'analyse (période, région).

GOUVERNANCE DES DONNÉES

RGPD, HDS, CNIL

Mesures issues de la fiche CNIL (novembre 2017) : minimisation et finalité (noms et adresses exclus de Gold), pseudonymisation du patient en Silver avec clé conservée hors cluster, Bronze à accès restreint, rôles par profil (praticiens, direction), journal d'audit, hébergeur certifié HDS lié par contrat (article 28), durée de conservation fixée par couche, effacement d'un patient par son pseudonyme, registre des traitements, analyse d'impact (AIPD) et DPO désigné.

COUVERTURE DES EXIGENCES

Couches Bronze / Silver / Gold	Zone Cloudera : trois cartes reliées par tMap et HiveQL
Flux de bout en bout	Sources → Talend → HDFS → Hive → Power BI, chaque flèche porte son composant ou protocole
Erreurs et rejets	Dossier /rejets alimenté par la sortie reject de tMap, avec journal d'audit
Doublons et valeurs nulles	Étape TRANSFORM de Talend, carte Silver
Pseudonymisation RGPD	Carte Silver, bandeau Gouvernance (clé hors cluster)
HDS, rôles et droits, traçabilité	Bandeau Gouvernance, accès par rôle sur Hive, Bronze à accès restreint
Fréquence d'exécution	Libellé de fréquence sur chaque source
Élasticité et scalabilité	Note sous Hive : scale-out par ajout de DataNodes