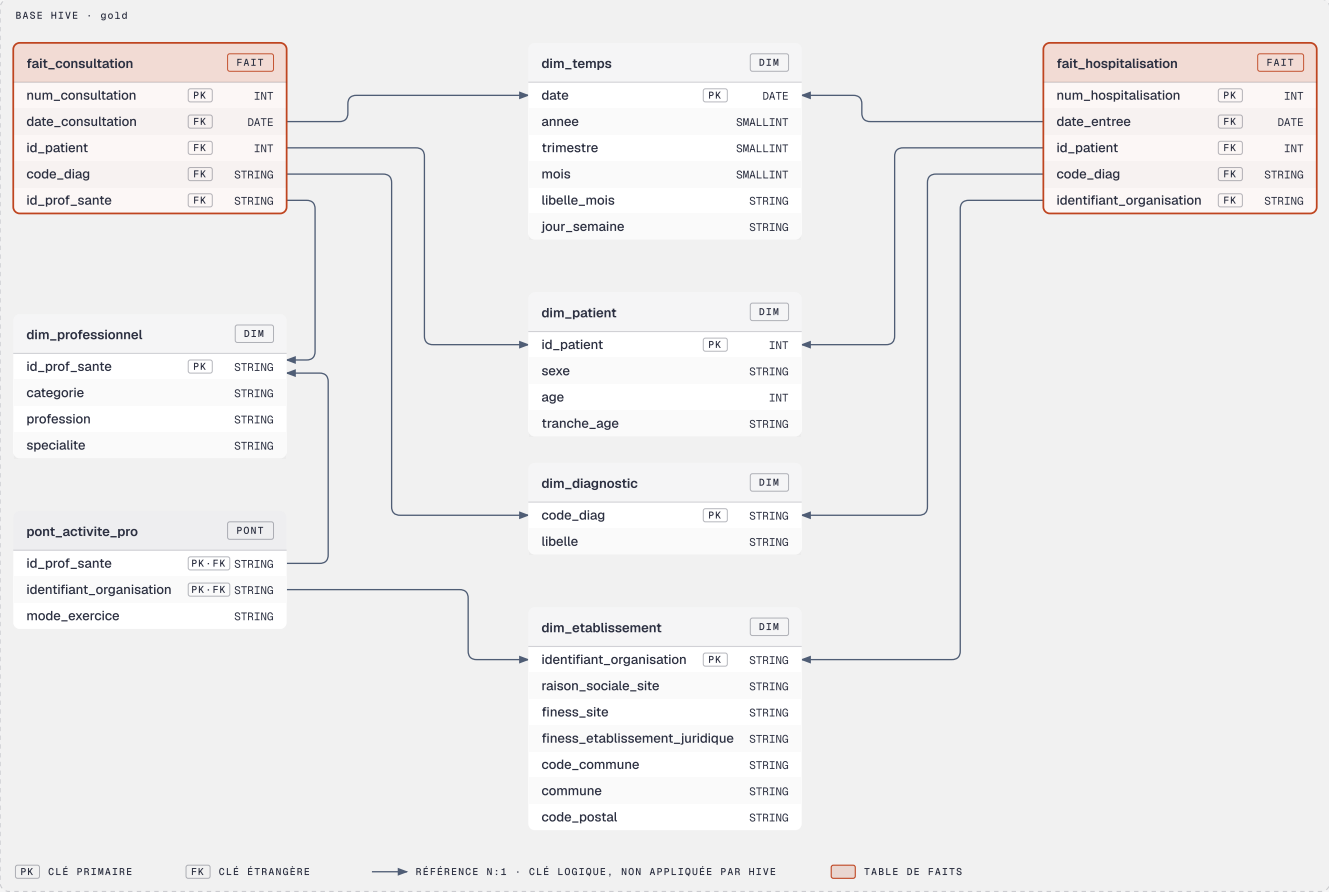
CLOUD HEALTHCARE UNIT · COUCHE GOLD

Schéma de la base décisionnelle : constellation de faits

Deux tables de faits (en orange) partagent les dimensions temps, patient, diagnostic et établissement. Une consultation ne porte pas d'établissement : il lui est rattaché par le professionnel, au travers d'une table de pont ; la pondération (1 ÷ nombre d'établissements du professionnel) est calculée dans Power BI. Ce pont est construit à partir de activite_professionnel_sante.csv (identifiant du professionnel, identifiant_organisation, mode_exercice) ; les consultations dont le professionnel est absent de ce fichier ou sans établissement sont rattachées à une ligne « inconnu » de dim_etablissement. Le sexe et la tranche d'âge viennent de dim_patient (sans nom ni adresse). Un troisième fait, fait_satisfaction, rejoint cette constellation par dim_etablissement (voir plus bas).



Des tables aux vues demandées

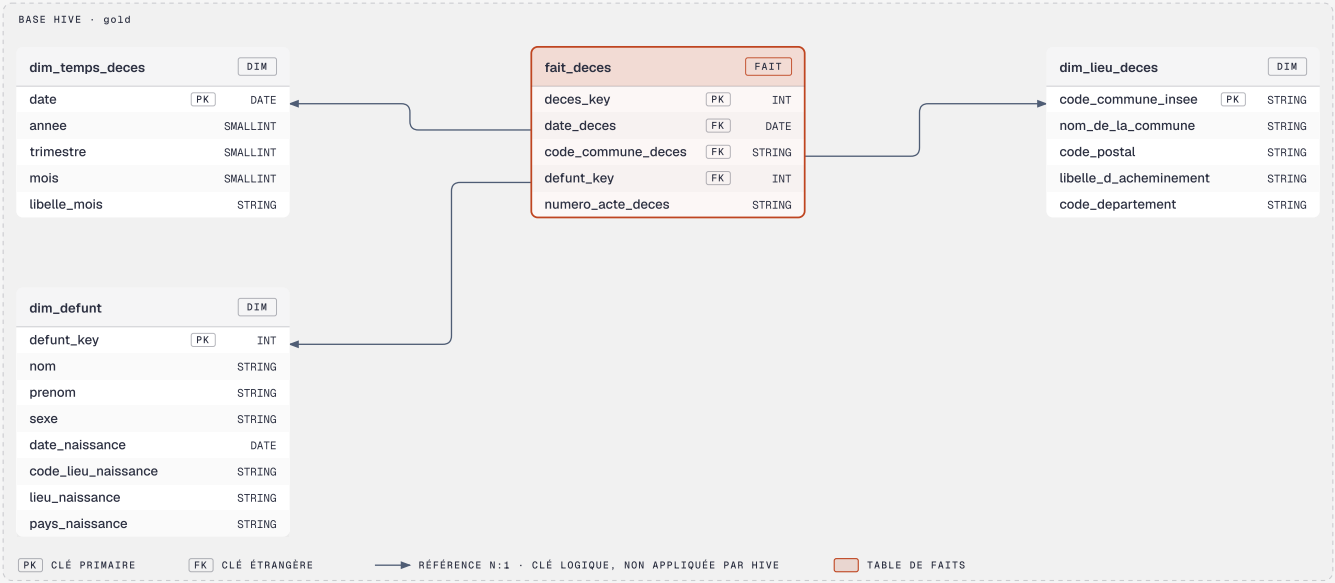
Les faits ne stockent aucune mesure : le nombre d'événements est le nombre de lignes (COUNTROWS dans Power BI). Les taux sont calculés dans Power BI : nombre d'événements ÷ nombre de patients distincts du même filtre.

BESOIN	TABLES UTILISÉES	MESURE
Taux de consultation dans un établissement X sur une période Y	fait_consultation · dim_temps · dim_professionnel · pont_activite_pro · dim_etablissement	consultations pondérées (1 ÷ nombre d'établissements du professionnel) ÷ patients
Taux de consultation par diagnostic X sur une période Y	fait_consultation · dim_diagnostic · dim_temps	consultations ÷ patients
Taux global d'hospitalisation sur une période Y	fait_hospitalisation · dim_temps	hospitalisations ÷ patients
Taux d'hospitalisation par diagnostic sur une période	fait_hospitalisation · dim_diagnostic · dim_temps	hospitalisations ÷ patients
Taux d'hospitalisation par sexe, par âge	fait_hospitalisation · dim_patient (sexe, tranche_age)	hospitalisations ÷ patients
Taux de consultation par professionnel	fait_consultation · dim_professionnel	consultations ÷ patients

Les clés sont les clés réelles des sources : id_patient, code_diag, id_prof_sante, identifiant_organisation, date (calendrier), code_commune. Les seules clés de substitution sont deces_key et defunt_key, car le fichier des décès n'a aucune clé fiable. Hive 1.1 n'applique pas les contraintes de clé : les relations sont logiques, vérifiées par le contrôle de cohérence référentielle de l'ETL.

Étoile des décès (source INSEE, indépendante)

Le fichier des décès ne contient aucun identifiant patient : il ne se relie à aucune dimension de la constellation. fait_deces forme donc une étoile à part, avec ses trois dimensions propres, dont un calendrier dédié (dim_temps_deces). Grain : un décès par ligne. dim_defunt reprend les attributs du fichier : identité (nom, prénom), sexe, date et lieu de naissance. Le nom de la commune et le code postal viennent d'un fichier de référence des communes (Code_commune_INSEE, Nom_de_la_commune, Code_postal, Libellé_d_acheminement), à rapprocher de code_lieu_deces ; le département se déduit des deux premiers caractères du code commune. Aucune donnée ne donne la région : la vue par région du sujet n'est pas réalisable avec ces données. L'âge au décès se calcule dans Power BI à partir de date_naissance et de la date du décès.

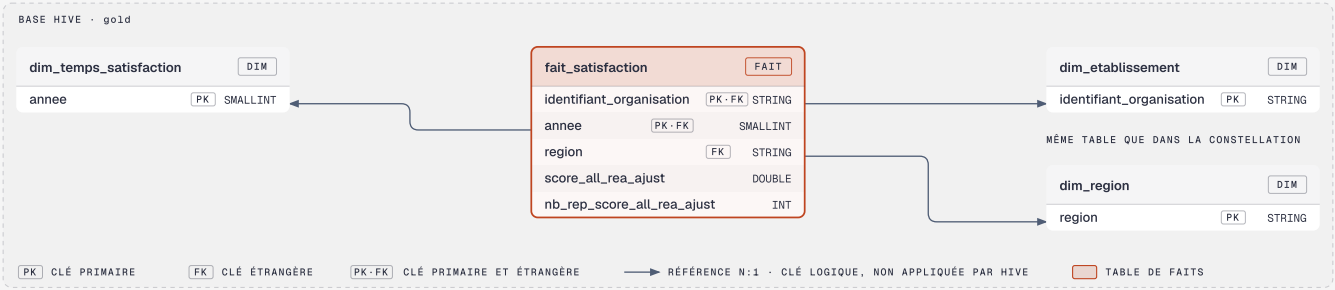


BESOIN	TABLES UTILISÉES	MESURE
Nombre de décès par localisation sur l'année 2019 (optionnel ; par département, la région n'est pas disponible)	fait_deces · dim_temps_deces (annee = 2019) · dim_lieu_deces (code_departement)	nombre de lignes de fait_deces (COUNTROWS dans Power BI)

Règle de lecture : des faits qui partagent au moins une dimension forment une constellation (consultations, hospitalisations et satisfaction). fait_deces ne partage aucune dimension : c'est une étoile isolée. Le fichier de référence des communes n'est pas encore dans DATA 2024 : source à ajouter ; à vérifier à sa réception : une commune peut avoir plusieurs codes postaux, donc plusieurs lignes pour un même code commune. Qualité du fichier (25 088 208 lignes) : numero_acte_deces n'est pas unique (d'où la clé de substitution deces_key) ; 89 863 dates de naissance mal formées et 550 vides ; 70 naissances postérieures au décès ; 10 934 codes de lieu de décès vides ; pays_naissance renseigné pour 8,5 % des lignes seulement. À traiter en Silver (valeurs « inconnu », rejets).

Satisfaction (ESATIS48H) : un troisième fait de la constellation

Source : résultats de satisfaction des patients hospitalisés plus de 48 h (MCO), un fichier par année (2017, 2019, 2020). Chaque ligne du fichier est un site (finess_geo). Préfixé de la lettre F, finess_geo donne exactement identifiant_organisation : 97,2 % des sites en 2017, 99,0 % en 2019 et 99,7 % en 2020 se retrouvent dans etablissement_sante.csv. fait_satisfaction dépend donc de la même dim_etablissement que fait_hospitalisation et que le pont : c'est un troisième fait de la constellation (la boîte dim_etablissement ci-dessous est la même table que plus haut). Grain : un site par année. L'identifiant finess du fichier (entité juridique) n'est pas repris : il ne se rattache qu'à 41 % des établissements via finess_etablissement_juridique. Seules deux dimensions sont propres à la satisfaction : l'année (absente du fichier, tirée de son nom) et la région (texte du fichier, sans code INSEE). Les autres scores (accueil, prise en charge, chambre, repas, sortie, recommandation) ne sont pas demandés par le sujet et ne sont pas repris.



BESOIN	TABLES UTILISÉES	MESURE
Taux global de satisfaction par région sur l'année 2020 (optionnel)	fait_satisfaction · dim_temps_satisfaction (annee = 2020) · dim_region	moyenne de score_all_rea_ajust pondérée par nb_rep_score_all_rea_ajust

Identifiant : identifiant_organisation = « F » + finess_geo (transformation de l'ETL). Les sites sans correspondance (32 en 2017, 12 en 2019, 4 en 2020) sont rattachés à la ligne « inconnu » de dim_etablissement. Qualité des fichiers : 25 à 46 % de scores vides selon l'année ; orthographe de region différente selon l'année (« Ile de France » et « Ile-de-France », « Hauts de France » et « Hauts-de-France ») à normaliser en Silver ; fichier 2020 au format .xlsx, 2017 et 2019 en CSV cp1252 séparé par « ; » ; le fichier 2017 n'a pas taux_reco_brut ni nb_reco_brut. Seul ESATIS48H est retenu : les fichiers ESATISCA (chirurgie ambulatoire) sont hors périmètre, à confirmer.